

Ответы на вопросы по математической статистике

1. Первичное описание выборки и смысл характеристик

1.1 Что такое выборка и чем она отличается от генеральной совокупности?

Выборка — это подмножество объектов, отобранных из генеральной совокупности согласно определённому правилу или методу для проведения статистического исследования.

Генеральная совокупность — это всё множество объектов, относительно которых мы хотим сделать выводы в рамках исследования.

Основные различия:

- Генеральная совокупность включает **все объекты** интереса, а выборка — только **часть из них**, которые мы непосредственно обследуем
- Выборка используется, когда исследование всей генеральной совокупности невозможно или нецелесообразно из-за ограничений по времени, стоимости или доступности данных
- По выборке мы делаем **статистические выводы** о генеральной совокупности

1.2 Как определяется эмпирическая функция распределения и какой у неё смысл?

Эмпирическая функция распределения (ЭФР) определяется как функция:

$$F_n(x) = \frac{\text{число элементов выборки, не превышающих } x}{n} \quad (1)$$

где n — объём выборки.

Смысл ЭФР:

- Это **ступенчатая функция**, которая для каждого значения x показывает долю элементов выборки, не превышающих x
- ЭФР является **оценкой теоретической функции распределения** генеральной совокупности
- Термин «эмпирическая» означает, что функция определяется по результатам опыта, то есть по набору наблюдаемых данных

1.3 Почему ЭФР является ступенчатой функцией?

ЭФР является **ступенчатой функцией**, потому что:

1. Она изменяется **только в точках наблюдаемых значений** выборки
2. В каждой точке выборки функция совершает **скачок на величину $1/n$** (где n — объём выборки)
3. Между соседними значениями выборки функция **остаётся постоянной**

Это связано с дискретной природой выборки: ЭФР накапливает относительные частоты только в тех точках, где есть наблюдаемые данные.

1.4 Что показывает гистограмма и как выбор ширины интервала влияет на выводы?

Гистограмма показывает распределение частот данных по интервалам.

Влияние ширины интервала:

- **Слишком узкие интервалы:**
 - Гистограмма получается «зашумлённой»
 - Много пустых или малозаполненных столбцов
 - Трудно увидеть общую форму распределения
- **Слишком широкие интервалы:**
 - Теряются важные детали распределения
 - Сглаживаются особенности (моды, асимметрия)
 - Может создаться ложное впечатление о форме распределения

Правильный выбор ширины позволяет выявить истинную структуру данных и сделать корректные выводы о распределении.

1.5 Чем отличается выборочное среднее от медианы с точки зрения устойчивости к выбросам?

Среднее арифметическое:

- Чувствительно к выбросам
- При наличии экстремальных значений среднее **сильно смещается** в сторону выброса
- Использует **все значения** выборки при расчёте

Медиана:

- **Устойчива** к выбросам
- Для расчёта медианы учитывается только порядок значений, а не их величина
- Медиана имеет точку разрыва 50%, что означает: до половины данных могут быть выбросами **без влияния** на её значение

Вывод: При наличии выбросов медиана даёт более надёжную оценку центральной тенденции.

1.6 В чём разница между смещённой и несмещённой дисперсией и почему возникает поправка $n - 1$?

Смещённая дисперсия:

$$s_{\text{смещ}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (2)$$

Несмещённая дисперсия:

$$s_{\text{несмещ}}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (3)$$

Различия:

- Смещённая используется для **генеральной совокупности** (делится на N)
- Несмещённая применяется для **выборки** (делится на $n - 1$)

Почему $n - 1$?

1. Использование выборочного среднего $\bar{x}$ вместо истинного математического ожидания приводит к **занижению дисперсии**
2. Поправка $n - 1$ компенсирует это смещение, делая оценку **несмещённой**
3. При большом объёме выборки ($n > 100$) разница между оценками становится незначительной

1.7 Как по выборочным характеристикам можно сделать вывод о симметрии распределения?

Признаки симметрии:

1. **Сравнение среднего и медианы:**
 - Если $\bar{x} \approx Me$ — распределение симметрично
 - Если $\bar{x} > Me$ — правосторонняя асимметрия
 - Если $\bar{x} < Me$ — левосторонняя асимметрия
2. **Коэффициент асимметрии** (теоретически)
3. **Визуальный анализ:**
 - Гистограмма должна быть приблизительно симметрична относительно центра
 - ЭФР должна иметь S-образную форму
4. **Сравнение квартилей:**
 - Для симметричного распределения: $Q_2 - Q_1 \approx Q_3 - Q_2$

1.8 Почему наличие выбросов влияет на среднее сильнее, чем на медиану?

Причины:

1. Среднее арифметическое учитывает **все значения** выборки при расчёте:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (4)$$

Выбросы напрямую входят в сумму и «тянут» среднее в свою сторону

2. Медиана зависит только от **порядка значений**, а не от их величины

- Медиана — это центральное значение упорядоченной выборки
- Экстремальные значения не влияют на положение медианы, пока не меняют порядок центральных элементов

3. **Свойство устойчивости:** медиана мало меняется при изменении одного-двух элементов массива, в то время как среднее может существенно измениться

Пример: Если в выборке $\{1, 2, 3, 4, 5\}$ заменить 5 на 100, то:

- Среднее изменится с 3 до 22
- Медиана останется равной 3

Это делает медиану **надёжной мерой** центральной тенденции при наличии выбросов.