РАЗДЕЛ I

3 Работа с гистограммой распределения

Всегда смотрите на график до расчёта статистик. Форма распределения определяет, какие меры центра и разброса будут информативны. Одно и то же среднее может описывать совершенно разные структуры данных — без визуализации легко сделать ошибочный вывод

Справка. (на лекции не было)

Выборочный коэффициент <u>асимметрии</u> $\overline{\gamma}_1 = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{X_i - \overline{X}}{\overline{\sigma}}\right)^3$

$\overline{\gamma}_1 \approx 0$ – симметричное (нормальное распределение)

$\overline{\gamma}_1 > 0$ – длинный хвост **справа**, пик смещён влево

$\overline{\gamma}_1 < 0$ – длинный хвост **слева**, пик смещён вправо

Для правоскошенных распределений: мода < медиана < среднее
Для левоскошенных: среднее < медиана < мода

Выборочный <u>эксцесс</u> $\overline{\gamma}_2 = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{X_i - \overline{X}}{\overline{\sigma}}\right)^4 - 3$

$\overline{\gamma}_2 \approx 0$ – как у нормального распределения

$\overline{\gamma}_1 > 0$ – длинный хвост **справа**, пик смещён влево

$\overline{\gamma}_1 < 0$ – длинный хвост **слева**, пик смещён вправо

$|\overline{\gamma}_1| > 0,5$ или $|\overline{\gamma}_2| > 0,5$ — уже заметное отклонение от нормальности, требующее внимания при интерпретации

1 Нормальное распределение

Выборка объёма n = 100
Среднее: 50.32
Медиана: 51.26
Дисперсия: 103.29
Ст. откл.: 10.16
Асимметрия: -0.31
Эксцесс: 0.95

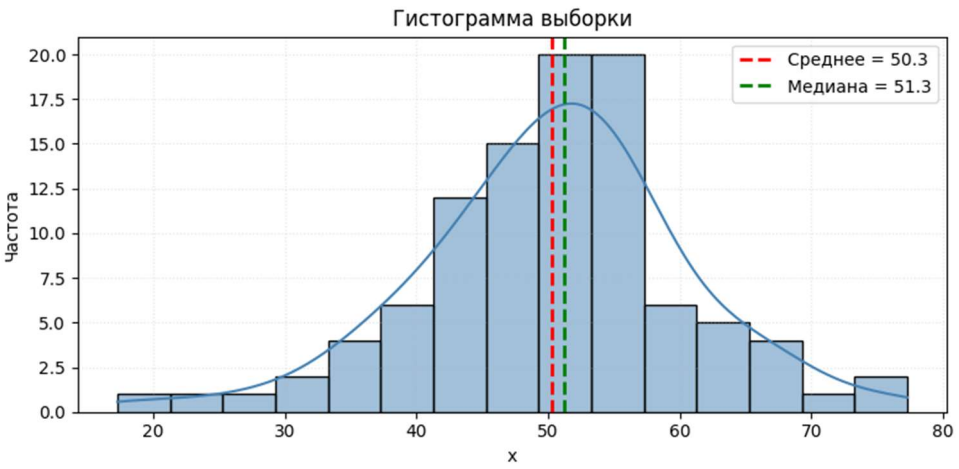

1.1 Что мы видите на гистограмме?

Один выраженный пик в центре, симметричные «спады» влево и вправо, форма напоминает колокол

1.2 Какие выводы можно сделать о форме распределения?

Распределение унимодальное (один пик) и приблизительно симметричное. Асимметрия ≈ 0 подтверждает симметрию

1.3 Почему среднее и медиана почти совпадают?

При симметрии левая и правая половины «зеркальны», поэтому 50% наблюдений лежат слева и 50% справа от центра. Среднее и медиана совпадают (с точностью до случайных флуктуаций). Среднее информативно при симметрии и использует все наблюдения

1.4 Вывод

Форма гистограммы и близость эксцесса к 0 позволяют предположить нормальность

2 Смесь двух нормальных (бимодальность)

Выборка объёма n = 100
Среднее: 50.73
Медиана: 48.97
Дисперсия: 201.15
Ст. откл.: 14.18
Асимметрия: 0.03

Эксцесс: -0.58

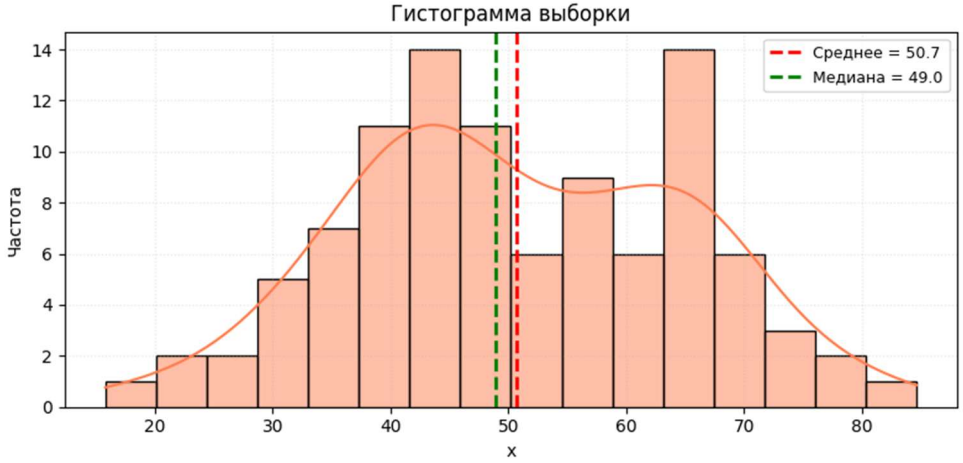

2.1 Что мы видите на гистограмме?

Два выраженных пика (моды) с «провалом» между ними. Пики частично перекрываются — нет резкого разрыва

2.2 Какие выводы можно сделать о форме распределения?

Выборка, вероятно, состоит из двух подгрупп с разными центрами. Бимодальность — сигнал о скрытом факторе (пол, оборудование, время и т. д.)

2.3 Почему среднее не совпадает и с одним из пиков?

Среднее — взвешенная сумма всех наблюдений. Оно «падает» в провал между пиками и не описывает ни одну из подгрупп. Это типичный артефакт усреднения разнородных данных

2.4 Какую меру центра выбрать?

Ни среднее, ни медиана не описывают «типичное» наблюдение. Правильный подход: 1) найти скрытый фактор 2) разделить выборку и анализировать подгруппы отдельно

2.5 Что делать?

1) *Не «сглаживать» гистограмму — бимодальность это важная информация*
2) *Убедиться, что пики реальны (гистограмма с другими интервалами, увеличение объема выборки)*

3) *Поиск причины бимодальности (пол, возраст, регион, тип клиента; данные собраны в разное время; данные получены на разном оборудовании, разными людьми; фактор неизвестен)*
4) *Если фактор неизвестен, то может быть применена* ***кластеризация***

Справка.

Кластеризация не объясняет почему есть два пика — она только помогает выделить подгруппы для дальнейшего исследования. Причину (скрытый фактор) всё равно нужно искать в предметной области

Алгоритм:

(1) Угадываем два центра (например, 40 и 70)
(2) Каждую точку относим к ближайшему центру, т. е. разбиваем данные на 2 группы
(3) Пересчитываем центры, как средние внутри получившихся групп
(4) Повторяем шаги (2)-(3), пока центры не стабилизируются

Исходная выборка (n=100, отсортирована):

15.8	20.2	24.3	26.0	28.4	29.2	30.6	30.9	32.0	32.7
33.7	34.0	35.1	35.4	37.0	37.1	37.2	38.2	38.5	38.5
39.1	39.5	39.5	40.1	40.7	40.7	41.4	41.4	41.9	41.9
42.0	42.4	43.1	43.2	43.5	43.8	44.0	44.4	44.5	44.9
45.1	45.9	46.1	46.5	46.6	46.9	47.3	47.7	48.0	48.7
49.3	49.3	49.5	50.5	51.4	52.1	53.1	53.6	53.8	55.4
55.4	55.7	56.1	56.1	57.4	57.8	58.1	58.3	59.0	60.1
60.9	61.3	61.5	62.0	63.7	63.8	63.9	64.0	64.6	64.6
64.8	64.9	65.2	66.1	66.2	66.6	66.7	67.1	67.8	68.8
69.2	69.4	69.4	69.5	73.1	73.7	75.7	78.3	78.4	84.6

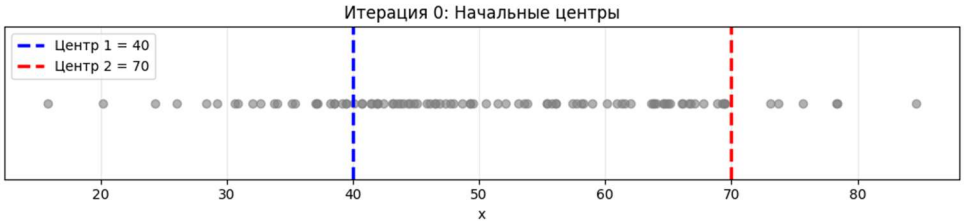

Начальные центры: $c_1 = 40$, $c_2 = 70$

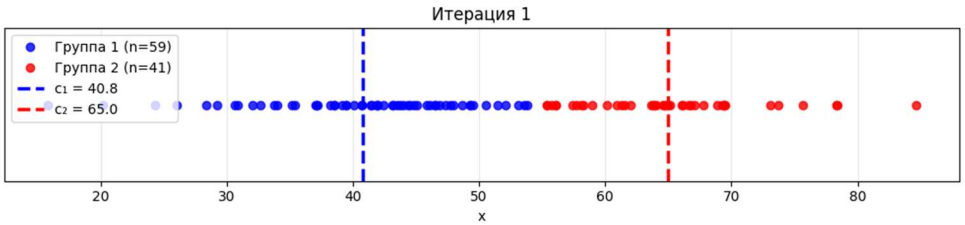

<u>Итерация 1:</u>

Группа 1: n = 59, центр = 40.82, диапазон = [15.8, 53.8]
Группа 2: n = 41, центр = 65.00, диапазон = [55.4, 84.6]

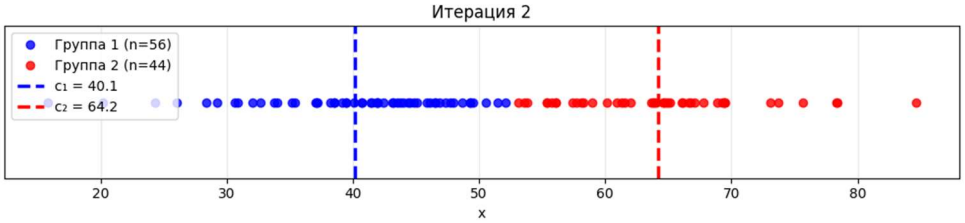

<u>Итерация 2:</u>

Группа 1: n = 56, центр = 40.14, диапазон = [15.8, 52.1]
Группа 2: n = 44, центр = 64.22, диапазон = [53.1, 84.6]

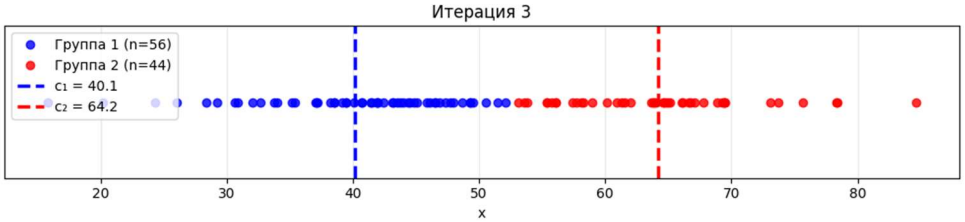

<u>Итерация 3:</u>

Группа 1: n = 56, центр = 40.14, диапазон = [15.8, 52.1]
Группа 2: n = 44, центр = 64.22, диапазон = [53.1, 84.6]

Две выделенные подгруппы:

Группа 1: 56 наблюдений, центр ≈ 40.1
Группа 2: 44 наблюдений, центр ≈ 64.2

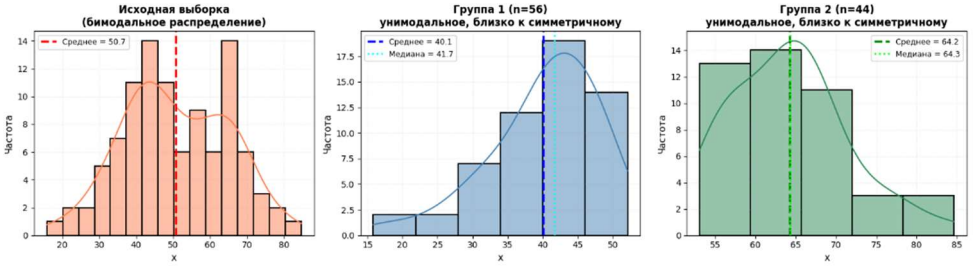

Статистики подгрупп:

Группа	n	Среднее	Медиана	σ	Асимметрия
Группа 1	56	40.14	41.67	7.85	-0.95
Группа 2	44	64.22	64.32	7.20	0.62

Вывод:

• Исходная выборка бимодальна — два пика на гистограмме

• После кластеризации каждая подгруппа унимодальна и близка к симметричной (среднее ≈ медиана)

• Небольшие отклонения от идеальной симметрии — результат случайности при малом объёме выборки (n=40–60)

• Бимодальность исходных данных вызвана смешением двух однородных подгрупп

3 Экспоненциальное распределение

Выборка объёма n = 100
Среднее: 41.65
Медиана: 33.26
Дисперсия: 567.28
Ст. откл.: 23.82
Асимметрия: 1.92
Эксцесс: 3.89

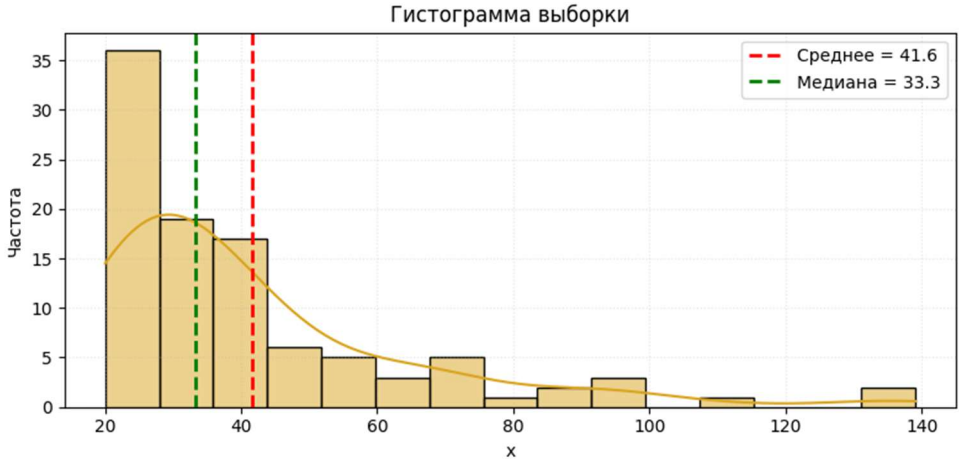

3.1 Что мы видите на гистограмме?

Один пик у левого края, длинный «хвост» тянется вправо. Большинство наблюдений сосредоточено в левой части, редкие большие значения — в правой

3.2 Какие выводы можно сделать о форме распределения?

Ярко выраженная правая асимметрия. Асимметрия ≈ 1.8 подтверждает это количественно

3.3 Почему среднее больше медианы?

Медиана менее чувствительна к экстремальным значениям — она делит выборку пополам независимо от величины хвоста

3.4 Какую меру центра выбрать?

Медиану. Среднее искажено хвостом и не отражает «типичное» наблюдение. Медиана устойчива к асимметрии и лучше описывает центр основной массы данных

3.5 Вывод

Распределение похоже на экспоненциальное

4 Равномерное распределение

Выборка объёма n = 100
Среднее: 49.98
Медиана: 49.08
Дисперсия: 324.90

Ст. откл.: 18.02
Асимметрия: 0.09
Эксцесс: -1.23

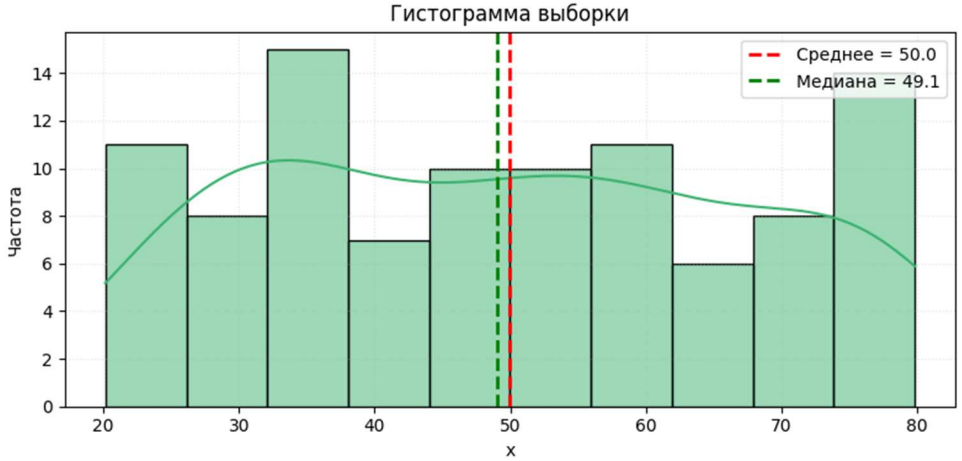

4.1 Что мы видите на гистограмме?
«Плоская» гистограмма — столбцы примерно одинаковой высоты, нет выраженного пика. Небольшие флуктуации объясняются случайностью
4.2 Какие выводы можно сделать о форме распределения?
Все значения в диапазоне примерно равновероятны. Отсутствие моды + симметрия (асимметрия ≈ 0) + отрицательный эксцесс (≈ −1.2) — признаки равномерного распределения
4.3 Какую меру центра выбрать?
Любую — среднее и медиана дают почти одинаковый результат из-за симметрии. Но важно указать границы диапазона $[x_{min}, x_{max}]$*, так как именно они определяют распределение*
4.4 Вывод
Распределение похоже на равномерное

5 Нормальное распределение + выбросы

Выборка объёма n = 100
Среднее: 52.47
Медиана: 51.30

Дисперсия: 161.44
Ст. откл.: 12.71
Асимметрия: 1.71
Эксцесс: 4.71

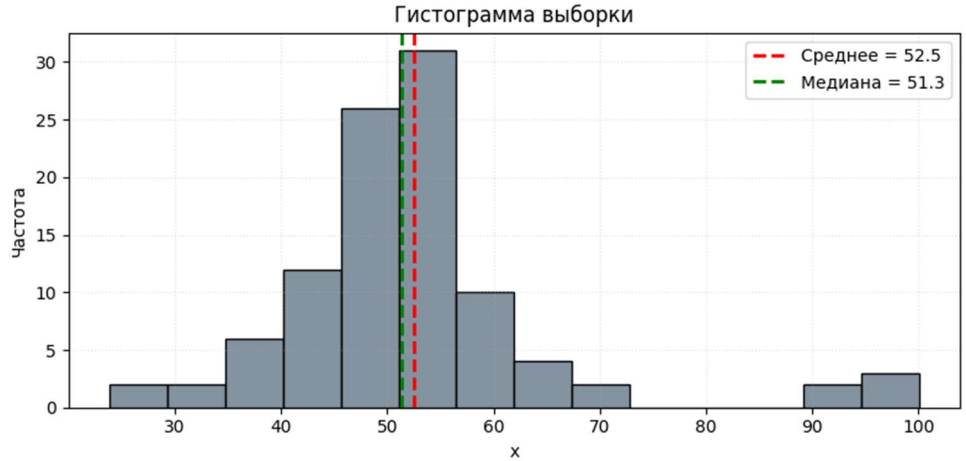

5.1 Что мы видите на гистограмме?
Основная масса образует симметричный колокол в центре, но справа есть столбики, отделённый зазором от основной группы
5.2 Как интерпретировать этот отдельный столбик?
Это группа экстремальных значений (выбросов). Они не являются случайными флуктуациями основного распределения — слишком далеко и компактно
5.3 Почему среднее больше медианы?
Выбросы «тянут» среднее вправо. Медиана устойчива — она определяется центральными 50% наблюдений и почти не смещается. Разница ≈4 единицы — признак влияния выбросов
5.4 Что говорит высокая асимметрия?
Распределение имеет длинный правый хвост. Это количественное подтверждение визуального впечатления о выбросах справа
5.5 Какую меру центра выбрать?
Медиану. Среднее искажено выбросами и не отражает центр основной массы данных
5.6 Что делать?

Не удалять выбросы автоматически — сначала выяснить их природу (ошибка или содержательная особенность)